인공 신경망 기초
(Artificial Neural Network)

인공 지능(Artificial Intelligence)이란?

인공지능(Artificial Intelligence, AI)은 기계가 사람처럼 학습하고 추론할 수 있는 능력을 가진 컴퓨터 시스템

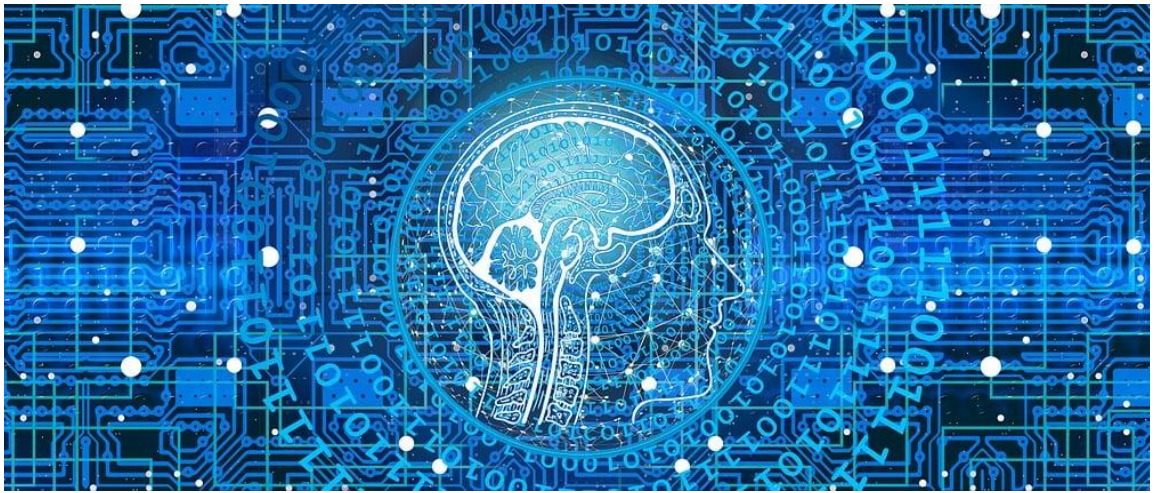

머신 러닝(Machine Learning)의 등장

머신 러닝은 데이터를 통해 예측을 만들고, 의사결정을 내리며, 패턴을 인식하는 등의 작업을 수행

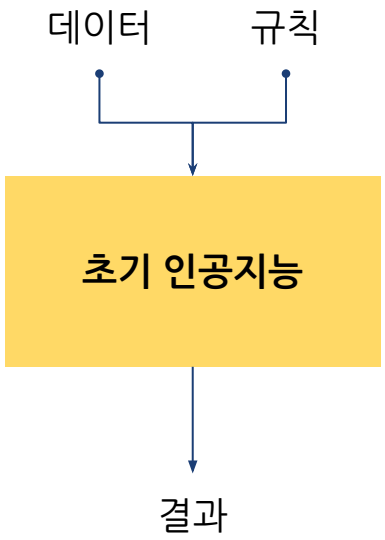

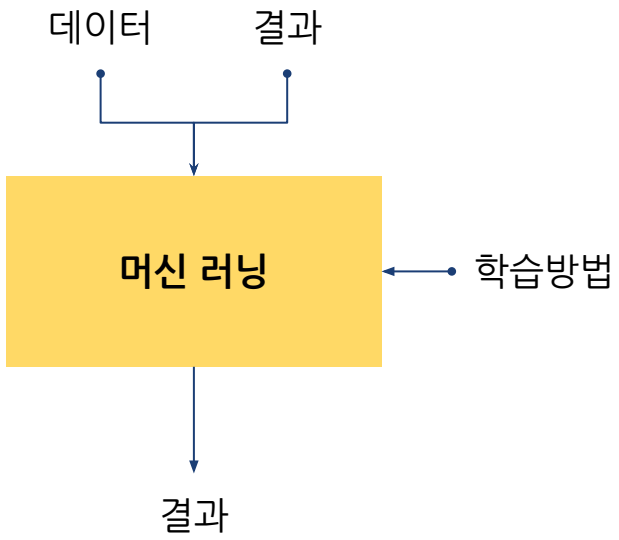

AI의 등장


THE TRUE ENIGMA
WAS THE MAN WHO CRACKED
THE CODE
BENEDICT CUMBERBATCH
KEIRA KNIGHTLEY
THE IMITATION GAME
COMING SOON

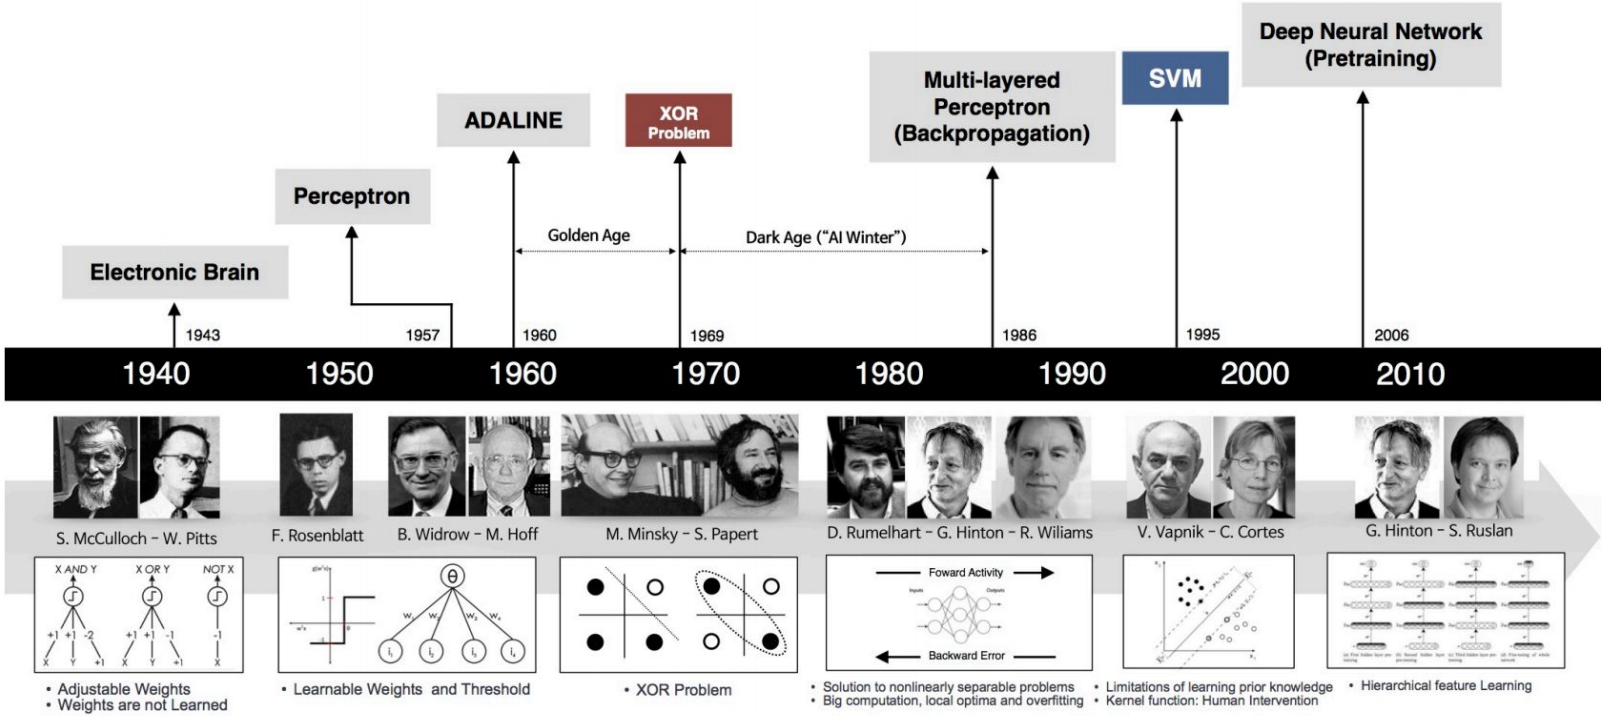
Deep Neural Network (Pretraining)
SVM
Multi-layered Perceptron (Backpropagation)
XOR Problem
ADALINE
Perceptron
Electronic Brain
Golden Age
Dark Age ("AI Winter")
1943
1957
1960
1969
1986
1995
2006
1940
1950
1960
1970
1980
1990
2000
2010
S. McCulloch - W. Pitts
F. Rosenblatt
B. Widrow - M. Hoff
M. Minsky - S. Papert
D. Rumelhart - G. Hinton - R. Wiliams
V. Vapnik - C. Cortes
G. Hinton - S. Ruslan
X AND Y
X OR Y
NOT X
Foward Activity
Backward Error
• Adjustable Weights
• Weights are not Learned
• Learnable Weights and Threshold
• XOR Problem
• Solution to nonlinearly separable problems
• Big computation, local optima and overfitting
• Limitations of learning prior knowledge
• Kernel function: Human Intervention
• Hierarchical feature Learning

CPU와 GPU

- **CPU(Central Processing Unit)**: 직렬 처리에 최적화된 몇 개의 코어로 구성
- **GPU(Graphics Processing Unit)**: 병렬 처리용으로 설계된 수 천 개의 소형 코어로 구성

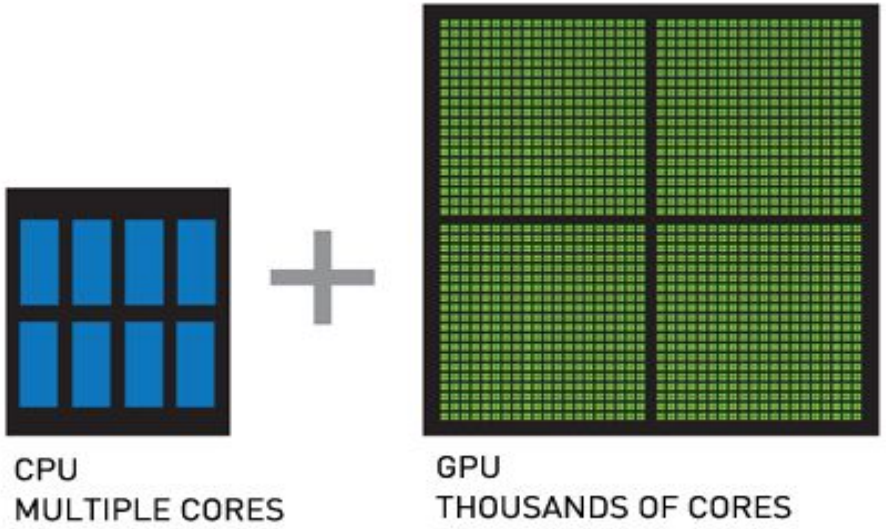


2012
합성곱 신경망(CNN)
2012년 이미지넷 챌린지에서 CNN 기반 딥러닝 알고리즘 AlexNet이 우승을 차지하며 딥러닝 부흥의 계기
"이미지 처리 딥러닝 본격화"
2014
적대적 생성 신경망(GAN)
생성자와 식별자가 서로 대립하며 데이터를 생성하는 모델
(기존 생성 AI 대비 성능 우수)
(DGGAN, starGAN 등 파생)
"생성 AI 분야의 새로운 혁신"
2015
텐서플로(Tensor Flow)
구글에서 인공지능 개발을 위한 프레임워크를 오픈소스로 공개
"오픈소스 문화에 기여"
2016
알파고(AlphaGo)
구글 딥마인드가 개발한 인공지능 바둑 프로그램
"인공지능 대중화"
2017
트랜스포머(Transformer)
구글이 개발한 자연어 처리 모델로 기존 RNN 구조의 단점을 극복하며 여러 모델 파생
(ELMo, BERT, GPT의 기반)
"언어모델의 혁신적 돌파구 마련"
아실로마 인공지능 원칙 (Asilomar AI principles)
윤리 원칙 등이 포함된 인공지능 원칙 선언
"윤리에 대한 인식 확산"
2018
자기지도학습 부각 (Self-supervised Learning)
비지도학습의 한 방법으로 얀 르쿤 교수가 중요성 강조
"기술 성숙의 시대"
2019
GPT-2 언어모델
BERT 언어모델
언어모델의 새로운 표준 역할
"기술 성숙의 시대"
2020
GPT-3
초대규모 언어모델의 시작
(1,750억개 매개변수)
"초대규모 모델의 범용성 부각"
알파폴드(AlpahFold)2
단백질의 구조 예측 분야에서 뛰어난 성과 달성
"난제 해결을 위해 AI 활용 본격화"
2021
AI 반도체 전성시대
GPU가 AI 반도체의 중심으로 부상
Nvidia 글로벌 10위 진입
DALL·E
Text to image 생성모델의 서막을 알린 달리
"멀티모달 모델의 서막"
2022
DALL-E2
미드저니
Stable diffusion
Pati
Imagen
Make A Movie
"멀티모달의 전성시대"

AI, ML, DL 요약

AI: 인공지능(AI)은 컴퓨터가 사람처럼 똑똑해지게 하는 모든 기술

ML: 기계학습(ML)은 컴퓨터가 스스로 배우게 하는 방법

DL: 딥러닝(DL)은 특히 복잡한 문제를 뇌처럼 생각해서 푸는 기계학습의 한 방법

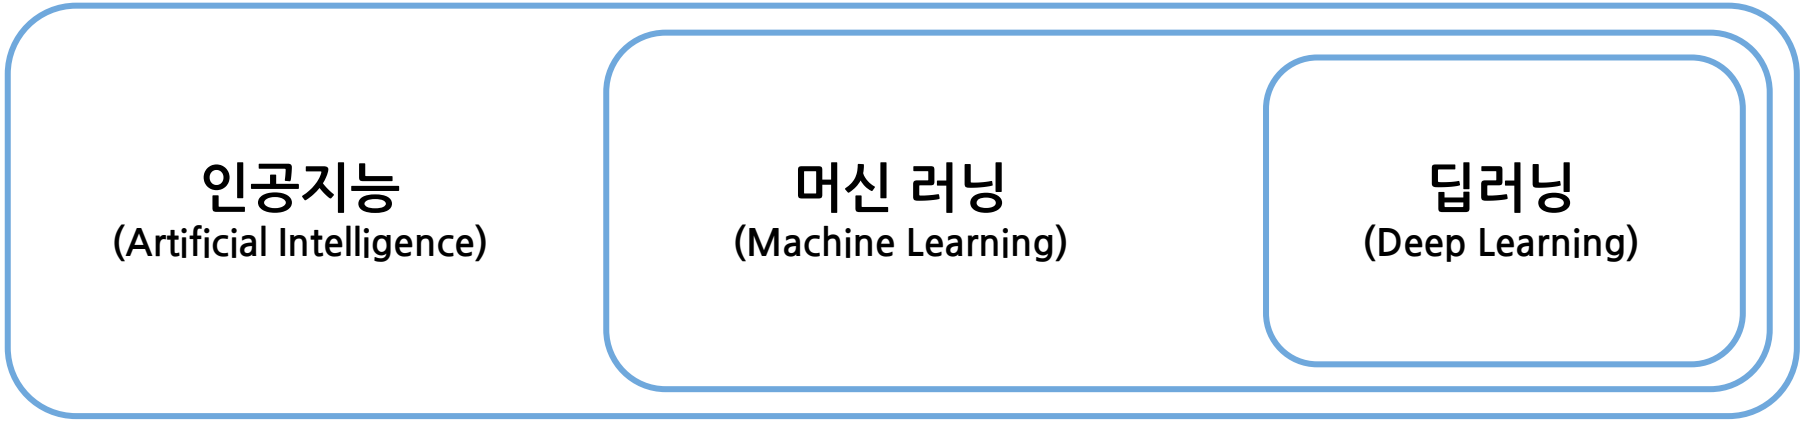

딥러닝(Deep Learning)의 등장

딥러닝은 인공신경망을 사용하는 이론으로, 인간의 뉴런과 유사한 방식으로 정보를 처리함

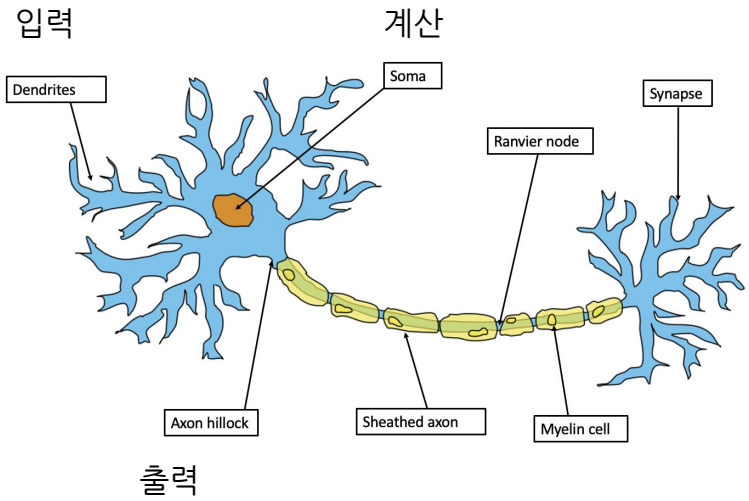

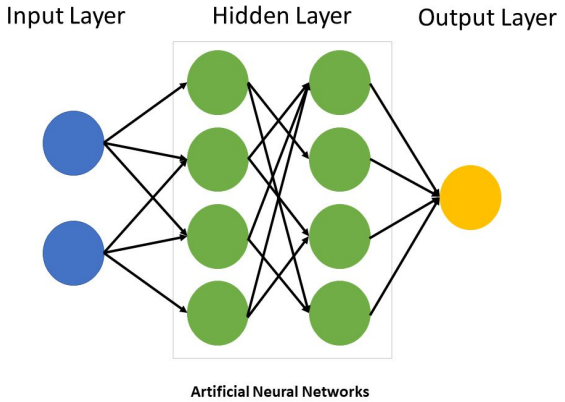

인공 신경망

여러 종류의 인공 신경망

2-layer Neural net

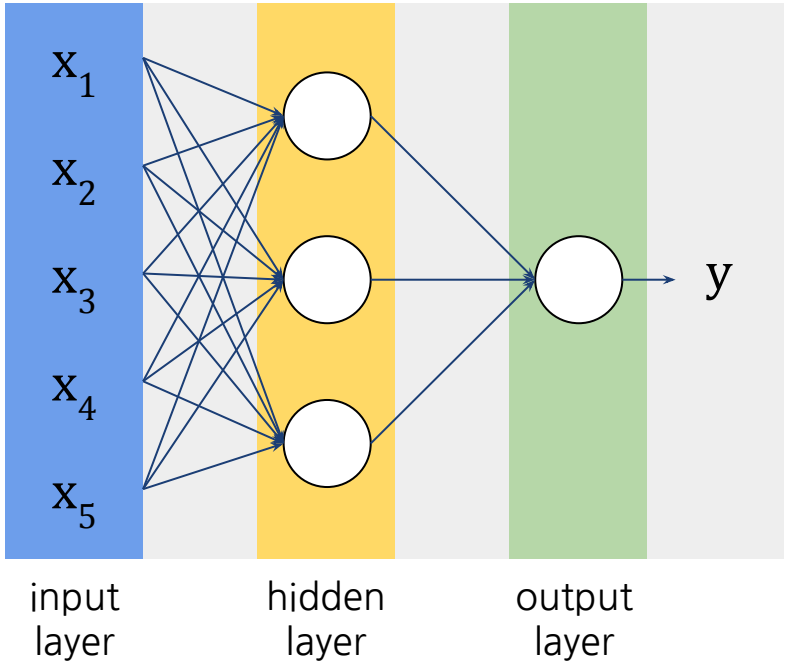

3-layer Neural net

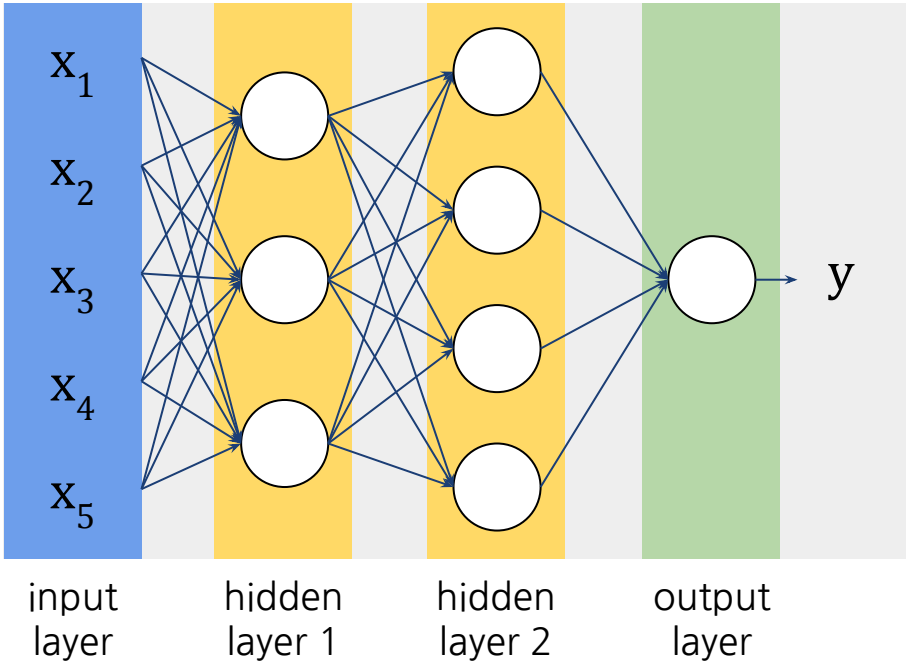

퍼셉트론(Perceptron)

프랑크 로젠블라트(Frank Rosenblatt)가 1957년에 제안한 초기 형태의 인공 신경망(Artificial Neural Network)

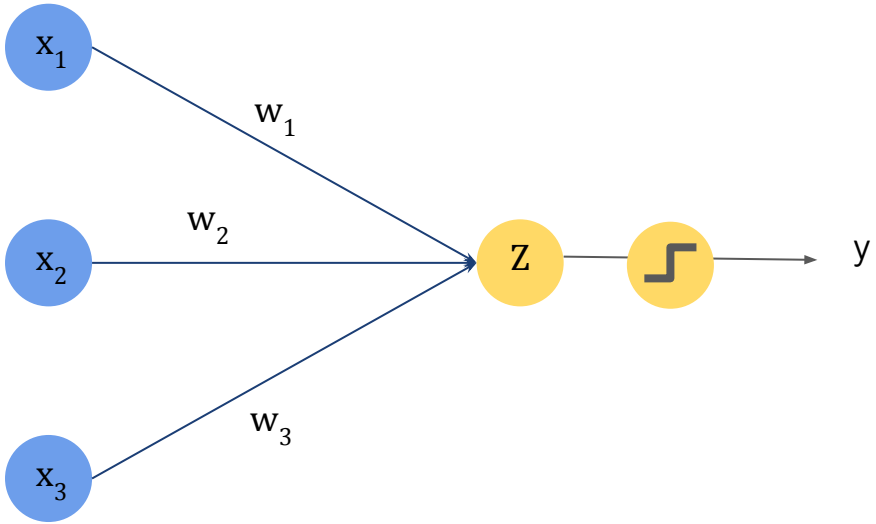

퍼셉트론(Perceptron)

원 = 뉴런(neuron) = 노드(node)
선 = 엣지(edge) = 파라미터(parameter)

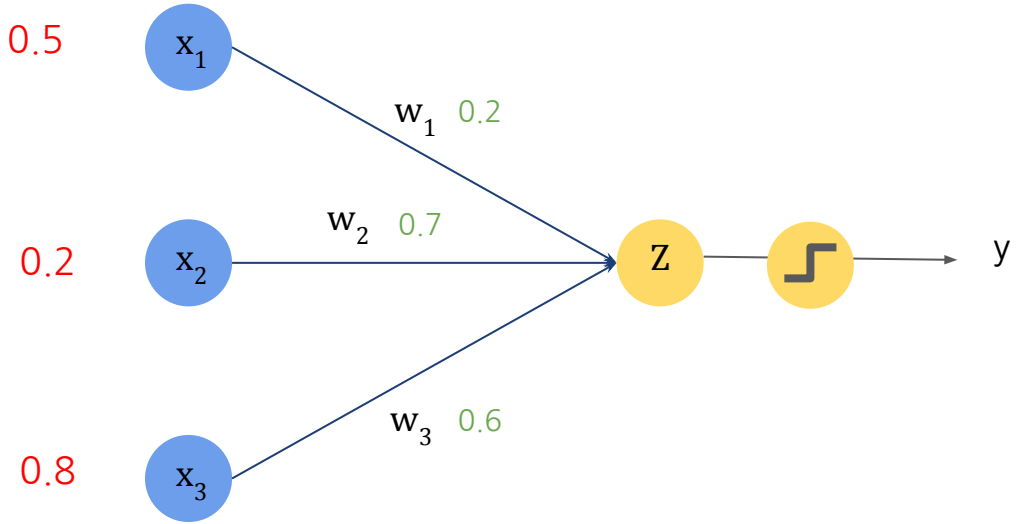

활성 함수(Activation function)

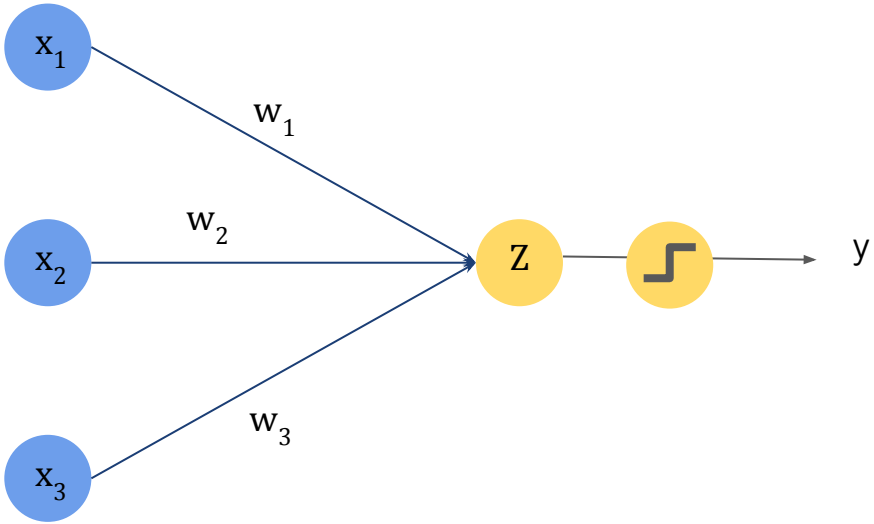

정의 : 입력값을 비선형적으로 변환하여 출력하는 함수

역할 :

1. 비선형성 부여 → 복잡한 패턴 학습 가능
2. 출력 값 범위 제한 → 학습 안정화
3. 뉴런 활성/비활성 결정

왜 필요한가 ?

- 선형 변환만 있으면 층을 쌓아도 표현력 한계
- 활성화 함수로 곡선, 복잡한 경계 학습 가능
- 분류, 예측 등 다양한 문제에 적합하게 변환

인공 신경망의 학습이란

인공 신경망이 입력 데이터와 출력 데이터 사이의 관계를 가장 잘 표현한 **w**(weight)와 **b**(bias)값을 찾아가는 과정

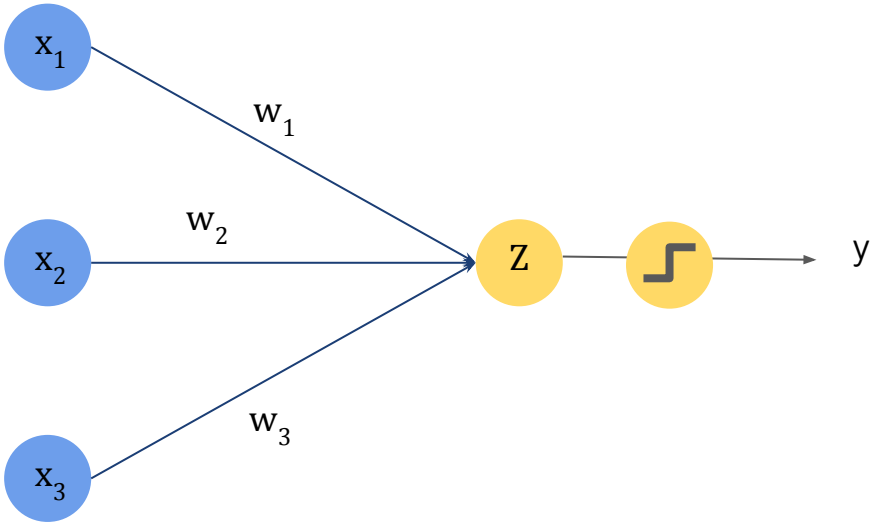

지도학습에서의 예시

예측값: $\hat{\mathbf{y}}$
정답(label): **y**

손실(loss) = **y**와 $\hat{\mathbf{y}}$ 사이의 거리 계산
(거리가 줄어드는 방향으로 학습)

손실함수 : **손실을 계산하는 함수**
MSE , MAE, Cross-Entropy

Cross-Entropy란?

- **정답(label) 분포**와 **모델의 예측 확률 분포**가 얼마나 다른지를 측정하는 값.
- 값이 **작을수록** 예측이 정답에 가깝다는 뜻.
- 주로 **분류 문제**에서 로 사용.

인공 신경망의 활용 예시

마트 매출 예측
(Regression)

- 평수
- 층수
- 가까운 아파트 단지 거리
- 가까운 마트 거리

평수	층수	아파트 거리	마트 거리	매출액
28	2	10	5	40
20	1	20	1	15

인공 신경망의 활용 예시

마트 매출 예측
(Regression)

- x1 : 평수
- x2 : 층수
- x3 :가까운 아파트 단지 거리
- x4 : 가까운 마트 거리
- y : 매출액

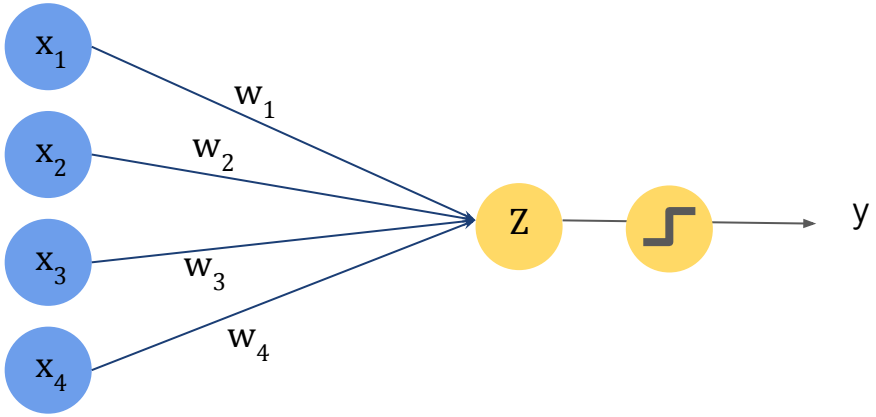

각각의 요소(factor)들에 가중치(weight; w)를 주고,
편향성(bias; b)을 파라미터로 하는 신경망을 만듦

인공 신경망의 활용 예시

스마트워치 구매 예측
(classification)

- 키
- 나이
- 연봉
- 이동거리

키	나이	연봉	이동거리	구매
176	28	6800	1100	O
168	20	6100	400	X

대량의 학습 데이터

딥러닝은 머신러닝에 비해 더 많은 데이터를 학습에 사용

Machine Learning

Deep Learning

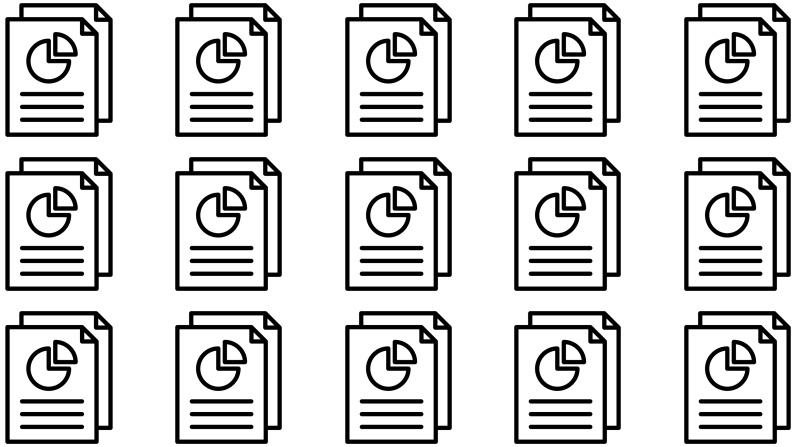

인공 신경망 요약

학습 데이터셋(Training set) + 기계 학습 알고리즘(Algorithm) + 모델(Model)

학습 데이터셋
(Training set)

알고리즘

예측 모델
(prediction)

인공 신경망의 학습

역전파(Back Propagation) : 미분을 기반으로 파라미터를 학습

1. 입력 데이터를 신경망에 넣고 출력값을 계산합니다.
2. 출력값과 실제값(정답) 사이의 오차(손실)를 계산합니다.
3. 이 오차를 신경망의 최종 층에서 역방향으로 전파시키면서 각 층의 가중치에 대한 기울기(미분값)를 계산합니다.
4. 계산된 기울기 값에 학습률을 곱하여 각 가중치를 업데이트합니다.
5. 이 과정을 데이터셋 전체에 대해 반복적으로 수행하면서 가중치를 점진적으로 최적화합니다.

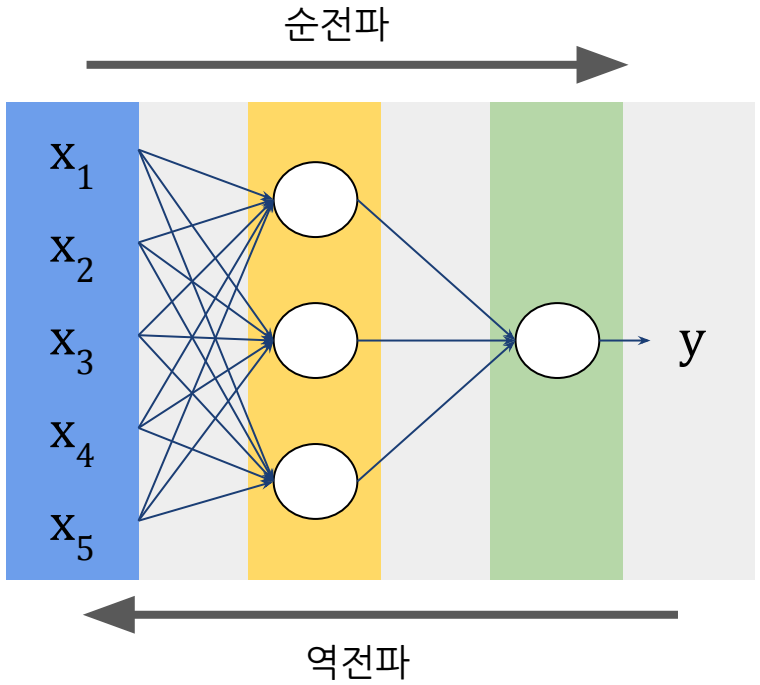

활성화함수 (Activation Function)

1. 정의:
   - 뉴런의 가중합을 입력으로 받아 출력을 생성하는 비선형 함수
   - 신경망에 비선형성을 도입하여 복잡한 패턴을 학습
2. 목적:
   - 비선형성 도입
   - 그래디언트 전파: 역전파 과정에서 그래디언트를 효과적으로 전달

활성화함수 (Activation Function)

Activation Functions

Sigmoid

$\sigma(x) = \frac{1}{1+e^{-x}}$

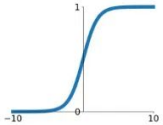

tanh

$\tanh(x)$

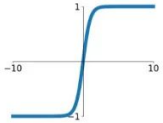

ReLU

$\max(0, x)$

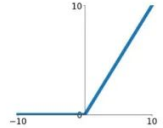

Leaky ReLU

$\max(0.1x, x)$

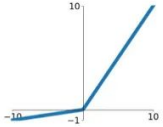

Maxout

$\max(w_1^T x + b_1, w_2^T x + b_2)$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

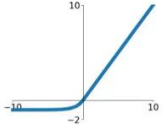

손실함수

손실 함수(Loss Function)는 머신러닝과 딥러닝에서 모델의 예측값과 실제값 사이의 차이를 측정하는 중요한 요소

평균 제곱 오차(Mean Squared Error, MSE):

- 회귀 문제에서 주로 사용
- 예측값과 실제값의 차이를 제곱하여 평균을 냄

평균 절대 오차(Mean Absolute Error, MAE):

- 회귀 문제에 사용
- 예측값과 실제값의 절대 차이의 평균을 계산

교차 엔트로피(Cross-Entropy):

- 분류 문제에서 주로 사용
- 이진 분류: Binary Cross-Entropy
- 다중 분류: Categorical Cross-Entropy

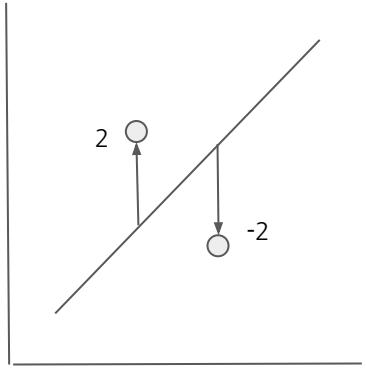

인공 신경망의 학습 - 최적화 함수

최적화 함수(Optimization Function)는 기계학습과 딥러닝에서 모델의 성능을 향상시키기 위해 사용되는 알고리즘
함수들의 주요 목적은 손실 함수(Loss Function)를 최소화하여 모델의 파라미터를 최적화하는 것

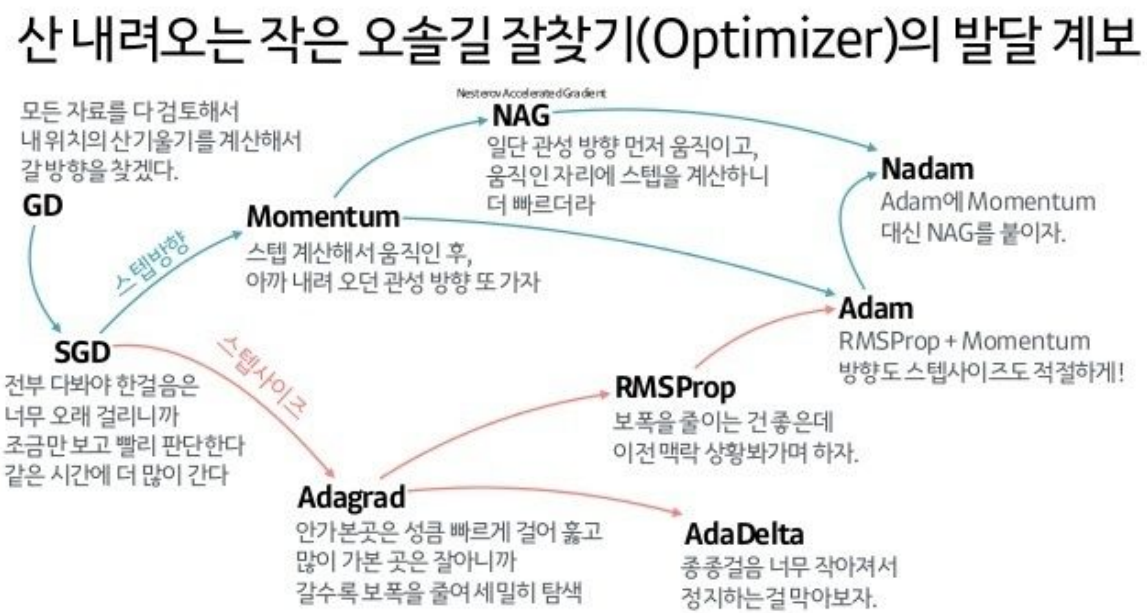

최적화 함수의 발전 - GD (gradient descent)

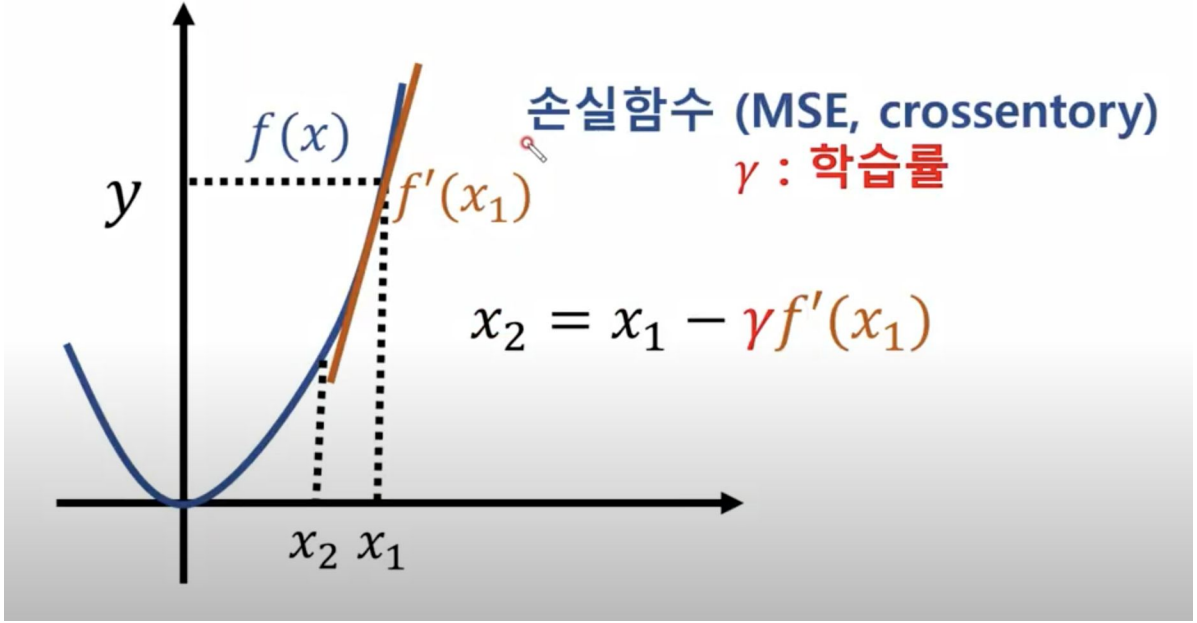

최적화 함수의 발전 - Momentum

모멘텀계수*속도

$$v = \alpha v - \gamma f'(x_1)$$

$$x_2 = x_1 + v$$

최적화 함수의 발전 - Adaptive Gradient Descent

$$h = h + f'(x_1)^2$$

$$x_2 = x_1 - \gamma \frac{1}{\sqrt{h}} f'(x_1)$$

최적화 함수의 발전 - RMS PROP

$$h = h\rho + f'(x_1)^2(1-\rho)$$

$$x_2 = x_1 - \gamma \frac{1}{\sqrt{h}} f'(x_1)$$

최적화 함수의 발전 - ADAM

$$v = \alpha v - \gamma f'(x_1)$$
$$h = h\rho + f'(x_1)^2(1-\rho)$$
$$x_2 = x_1 + \alpha v - \gamma \frac{1}{\sqrt{h}} f'(x_1)$$

역전파 알고리즘

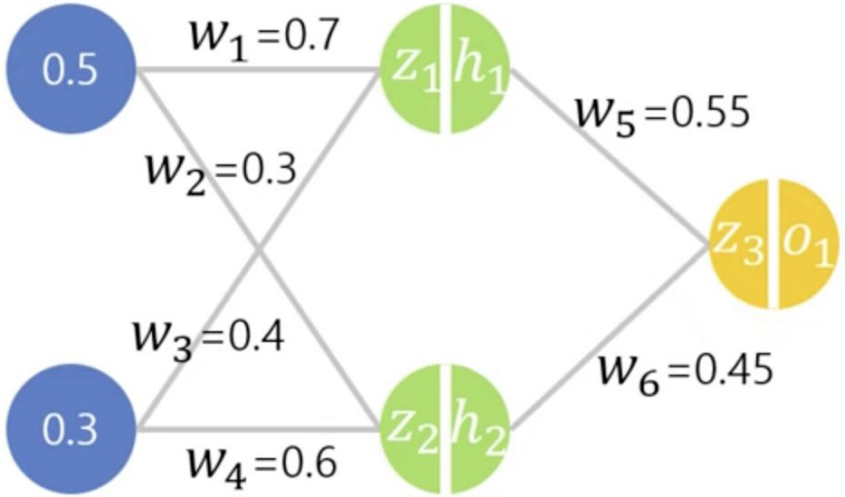

W1 를 구할려면?

$$\frac{\partial E}{\partial w_1} = \frac{\partial E}{\partial o_1} \cdot \frac{\partial o_1}{\partial z_3} \cdot \frac{\partial z_3}{\partial h_1} \cdot \frac{\partial h_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial w_1}$$

인공 신경망의 학습 데이터 구성 - batch

딥러닝에서 batch(배치)는 학습 데이터 전체를 **한 번에 다 쓰지 않고**, 일부 묶음 단위로 나눠서 학습하는 **데이터 처리 단위**를 말합니다.

왜 배치를 쓰나?

- **계산 효율**: 데이터가 너무 크면 한 번에 GPU 메모리에 안 들어감.
- **속도**: 작은 덩어리로 나누면 연산 병렬화가 쉬워져 학습이 빨라짐.
- **일반화 성능**: 배치 단위로 가중치를 조금씩 업데이트하면 과적합을 줄이는 효과가 있음.

용어	의미
Batch size	한 번에 학습에 사용하는 데이터 개수
Mini-batch	전체 데이터보다 작지만, 1개보다 큰 배치(실무에서 대부분 사용)
Epoch	전체 학습 데이터를 1번 모두 사용하는 과정
Iteration	한 epoch 안에서 배치가 몇 번 돌아가는지의 한 step

데이터셋(Dataset)

학습 데이터 세트(Training set) - 검증 데이터 세트(Validation set) - 평가 데이터 세트(Test set)

학습이 계속 되면 될수록 학습 데이터에 대한 “암기”가 일어나 성능이 저하됨.

이를 극복하려면

- 데이터 수가 굉장히 많아야 하며 다양해야 함
- Mini-batch Training을 해야함

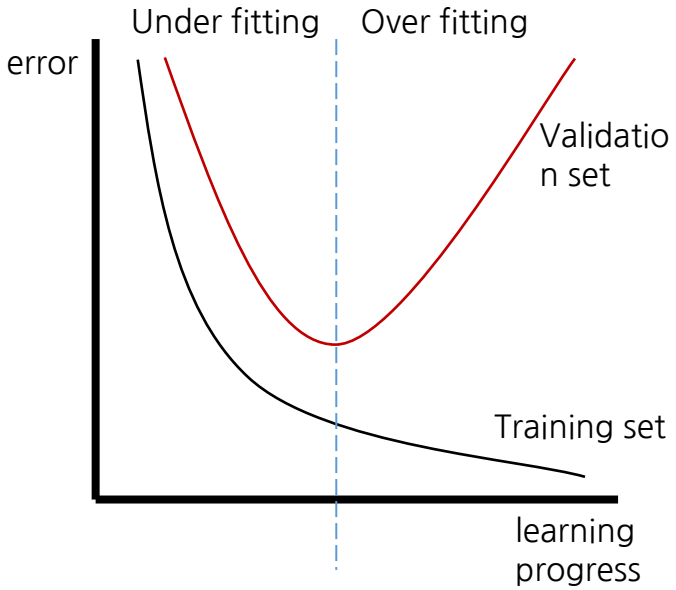

인공 신경망의 문제점과 발전

인공 신경망의 문제점

1. 너무 많은 파라미터 수
2. 많이 필요로 하는 학습 데이터
3. 오래 걸리는 학습 시간

딥러닝 학습 순서

1. 데이터 준비

1. **데이터 수집**
    - 센서, 웹 크롤링, 오픈 데이터셋 등에서 원본 데이터 확보
2. **데이터 전처리**
    - 결측값 처리, 이상치 제거, 정규화/표준화, 인코딩(문자 → 숫자)
3. **데이터 분할**
    - 학습(train), 검증(validation), 테스트(test) 세트로 나눔

딥러닝 학습 순서

2. 모델 설계

4. **모델 아키텍처 정의**
    - 층(layer) 수, 뉴런 수, 활성화 함수 선택
5. **손실 함수(loss function) 선택**
    - 예: MSE(회귀), Cross-Entropy(분류)
6. **최적화 알고리즘(optimizer) 선택**
    - SGD, Adam, RMSProp 등

딥러닝 학습 순서

3. 학습 실행

7. **배치(batch) 구성**
   - 전체 데이터를 Mini-batch 단위로 나눔
8. **반복(Epoch) 학습**
   - **(1)** `optimizer.zero_grad()` — 기울기 초기화
   - **(2)** Forward pass — 입력 → 예측값 계산
   - **(3)** 손실 계산 — 예측값과 정답 비교
   - **(4)** Backward pass — 오차를 역전파해 기울기 계산
   - **(5)** `optimizer.step()` — 가중치 업데이트
   -

딥러닝 학습 순서

4. 평가 & 저장

9. **검증 데이터로 성능 평가**
    - 오버피팅 여부 확인, 하이퍼파라미터 조정
10. **테스트 데이터 최종 평가**
    - 실제 사용 환경에서의 성능 확인
11. **모델 저장**
    - 학습된 파라미터(`.pt` / `.pth`) 저장

딥러닝 학습 순서

5. 배포 & 활용

12. **추론(Inference)**
    - 학습된 모델로 새로운 데이터 예측

13. **모니터링 & 재학습**
    - 데이터 변화에 따라 성능 유지